

Les utilisations possibles de l'Intelligence Artificielle dans la linguistique historique

Thomas HORRUT, Eliott CAMOU, Benjamin BADOUAILLE
Étudiants au Cycle Préparatoire de Bordeaux (CPBx)

Projet tutoré par Rachel Bawden



université
de BORDEAUX



BORDEAUX
INP

Enseirb-
matmeca

BORDEAUX
INP ENSC

0.1 Résumé

0.2 Abstract

0.3 Remerciements

Table des matières

0.1	Résumé	2
0.2	Abstract	2
0.3	Remerciements	2
	Table des figures	5
	Liste des tableaux	6
	Glossary	7
1	Introduction	8
2	La linguistique historique et l'Intelligence Artificielle	9
2.1	La linguistique historique	9
2.1.1	Introduction à la linguistique historique	9
2.1.2	Les différents principes	10
2.1.3	Les atouts de l'Intelligence Artificielle dans ce domaine	13
2.2	L'intelligence artificielle dans le Traitement Automatique des Langues	13
2.2.1	Introduction à l'apprentissage automatique	13
2.2.2	Traitement des données	16
2.2.3	Architectures neuronales utiles au TAL	18
3	Les contributions de l'IA dans la linguistique historique	23
3.1	Restauration de documents anciens	23
3.2	Déchiffrement de langues anciennes	25
4	Étude du cas de l'application de l'IA pour la reconstruction des proto-formes	27
4.1	État de l'art	27
4.1.1	Conceptualisation du problème	27
4.1.2	Dernières solutions neuronales	28
4.1.3	Limites d'applicabilité	29
4.2	Expérience sur une approche non supervisée	30
4.2.1	Méthode	30
4.2.2	Critiques	30
4.2.3	Compte-rendu de l'élaboration	31

Table des matières

5 Conclusion	33
5.1 Synthèse	33
5.2 Les différentes limites posées aujourd’hui	33
5.3 Les perspectives de l’IA dans la linguistique historique	33
Bibliographie	34
A Fine-tuning	36

Table des figures

Liste des tableaux

Glossaire

API Alphabet Phonétique International.(ASSOCIATION 1999). 27

distance d'édition C'est le nombre minimal d'opérations (insertion, substitution, suppression) à appliquer à une chaîne de caractères a pour obtenir la chaîne de caractères b . 16, 30, 32, 36

1 Introduction

Mise en contexte pour arriver à la problématique, quel est le potentiel de l'intelligence artificielle dans la linguistique historique ? ... ?

2 La linguistique historique et l'Intelligence Artificielle

Introduire le but de cette première partie, consistant à familiariser le lecteur à la linguistique historique et l'intelligence artificielle, pour permettre lui permettre de suivre la suite du mémoire.

2.1 La linguistique historique

2.1.1 Introduction à la linguistique historique

L'étude de l'évolution des langues est un aspect crucial de la linguistique générale. Bien que les conditions générales de cette évolution nécessitent une étude détaillée, il est important d'établir dès maintenant quelques principes sur la linguistique historique. Cette dernière se concentre sur l'histoire des langues, en utilisant à la fois des éléments provenant de la linguistique évolutive (de nature générale) et de la linguistique comparative, qui analyse les similitudes historiques entre les langues grâce à une méthode scientifique de comparaison des matériaux et des structures linguistiques.

Chaque langue a une histoire. Les conditions extérieures, sociales, de son existence évoluent, et la langue elle-même, dans son système et dans son aspect matériel, se transforme, passe par des états divers. Mais les possibilités d'étude sont limitées, notre connaissance de l'histoire d'une langue s'arrêtant à un certain moment, plus ou moins reculé, du passé. Or, les modalités de l'évolution d'une langue sont telles qu'elles donnent le moyen, dans certaines conditions, de projeter sur leur passé une estimation. La linguistique étant la discipline s'intéressant à l'étude du langage, elle se distingue de la grammaire, dans la mesure où elle n'est pas prescriptive mais descriptive. La linguistique a des rapports très étroits avec d'autres sciences, tout en étant très différente, comme l'ethnographie, ou l'anthropologie. Elle est introduite au XIX^e siècle (voir annexe). La linguistique peut se définir comme une science qui a pour objet l'étude du langage, des langues envisagées comme systèmes sous leurs aspects phonologiques, syntaxiques, lexicaux et sémantiques.

La langue est une partie du langage. C'est un produit social de la faculté du langage et un ensemble de conventions nécessaires, adoptées par une communauté pour permettre l'exercice de cette faculté chez les individus. C'est une institution sociale. Le langage quant à lui est un système de signes qui permet l'expression de la communication.

La linguistique historique étudie l'histoire et l'évolution des langues, et des familles des langues. Elle est utilisée, par exemple, dans le déchiffrement de textes anciens, usant de *lois universelles*

2.1. La linguistique historique

d'évolution, la tendance de la langue à évoluer suivant certaines *règles* régulières. Dans le cadre de l'article scientifique nous avons effectué, nous nous sommes basés sur ce principe. Dans le cas de la reconstruction de langue, la principale méthode de travail consiste à une comparaison entre les différents états d'une même langue (synchronie successives) ou entre des langues différentes mais issues d'un même ancêtre (comparaison), mais aussi à rechercher des concordances syntaxiques ou sémantiques régulières (loi universelles d'évolution) mettant en évidence la relation entre les différents états d'une langue ou d'un groupe de langues. Par exemple, ce travail de comparaison et de recherche permet de retrouver la langue mère à partir d'une langue fille, comme le latin à partir du français. La linguistique historique permet de caractériser la nature des évolutions, innovations et rétentions l'état initial et les états finaux (phonétique, phonologie, lexique, syntaxe etc.).

2.1.2 Les différents principes

Il existe deux manières d'aborder la linguistique historique : en étudiant une langue à un moment donné, sous un point de vue synchronique, ou en l'étudiant au cours du temps, sous l'angle diachronique. Nous allons nous attacher à aborder plus globalement l'étude des langues dans son aspect général, c'est-à-dire en ne négligent aucun aspect. La proximité entre des langues peut traduire une histoire commune. Comme vu précédemment, ces rapprochements se font par la comparaison entre les langues.

Cependant, il faut distinguer les emprunts des mots étant issus d'une langue plus ancienne : *Algorithme*, *girafe*, *orange*, sont des mots français empruntés à l'arabe. Enfin, les mots *main* et *mano* en espagnol ont la même signification et ont une origine commune. On dit alors qu'ils sont des *cognats*. Après avoir fait la distinction, on ne se penchera que sur les mots issus de l'évolution d'une langue plus ancienne, les *cognats*. Ainsi, on peut dire que deux langues ayant des caractéristiques voisines descendent d'une langue mère commune. Par exemple, les langues romanes comme l'espagnol et le français descendent du latin.

Ainsi, à partir de ces langues voisines, on peut tenter de reconstruire leur langue ancestrale, la *protolangue* ou langue mère. Selon plusieurs théories de linguistiques, cette *protolangue* est hypothétique et elle descendrait elle-même d'une langue plus ancienne encore. Pour reconstruire cette *protolangue*, on doit l'étudier sur plusieurs niveaux : la syntaxe, le lexique, la phonologie, la phonétique... De là, on peut aborder un processus récursif : à partir d'un ensemble de *protolangues* apparentées, on peut reconstruire une *protolangue* encore plus ancienne, et remonter un arbre généalogique des langues humaines de cette façon, vers l'Indo-européen par exemple (cf annexe).

Pour cela, la linguistique historique doit prendre en compte le sens des mots, mais aussi leur représentation essentielle, caractérisée par une suite de sons – elle-même représentée ensuite par des symboles. Cependant, les mots de deux langues peuvent être proches à cause d'un emprunt, d'une évolution commune des langues ou dû au hasard. Par exemple, *meli* veut dire *miel* en hawaïen et en grec ancien, sans qu'un lien entre les deux langues ne soit établi. Les emprunts sont très problématiques en linguistique historique, car lors de l'apprentissage, si des emprunts sont utilisés pendant le processus, le modèle de langue va prendre des mesures erronées, faussant ainsi les résultats.

Comme expliqué précédemment, l'évolution des langues se fait de façon régulière, quantifiable, et prévisible. Ces changements sont appelés *correspondances régulières*, ce sont des changements

prévisibles. Les transformations phonologiques qui changent sans exception un son (=phonème cf définition phonème) *A* de la langue 1 en un autre son *B* de la langue 2 témoignent d'une relation de parenté entre deux langues.

Un morphème est quant à lui le plus petit fragment morphologique d'un mot porteur de sens. Il peut être de nature lexical ou grammatical. En parallèle, on le considère également soit comme un thème morphologique, lorsqu'il porte le sens principal du mot, soit comme un affixe, dans le cas d'un préfixe ou d'un suffixe par exemple. Dans *chant-eur*, *jongl-eur*, ou *jou-eur*, le suffixe « -eur » signifie celui qui fait l'action. Ainsi, « eur » est un morphème. La Morphologie est le domaine de la linguistique étudiant les morphèmes et leur manière de composer des mots.

Les correspondances régulières sont détectées grâce à la méthode comparative. Pour cela, elle considère un ensemble de mots. Les mots doivent alors être apparentés selon leur sens, en prenant en compte les éventuels glissements sémantiques. Après cela, les emprunts doivent être écartés. Enfin, les régularités doivent être cherchées entre les mots et les différentes évolutions qui ont pu conduire des uns aux autres n'ont plus qu'à être inspectées. (rajouter tableaux, texte explication tableaux, sources tableau)

Sens	Swahili	Dawida
Mâcher	-tafuna	-dafuna
Couper un arbre	-tema	-dema
Arbre	m-ti	m-di
Feu	m-oto	m-odo
Envoyer	-tuma	-duma

Cette méthode met donc en lumière des cognats, c'est-à-dire deux mots de deux langues différentes qui dérivent de la même protolangue. On observe une correspondance régulière entre le /t/ du Swahili et le /d/ du Dawida.

Fisch	Poisson
Vater	Père
Fell	Peau
Ferkel	Porc
Voll	Plein

On observe aussi que la méthode marche mieux lorsque les deux langues ont divergées récemment. Par exemple le français et l'allemand, avec des correspondances de /f/ et /p/ à l'initiale, mais restant cependant incertain.

Ainsi, si des emprunts ne sont pas détectés, ils vont fausser toute mesure, en conduisant à sous-estimer la profondeur d'un ancêtre commun à plusieurs langues. Pour cela, on peut utiliser uniquement des mots simples existant individuellement dans chaque langue. Il existe des listes de mots du lexique simple, pouvant être exploités par les linguistes, comme par exemple les listes de Swadesh (https://en.wiktionary.org/wiki/Appendix:Latin_Swadesh_list).

Ces listes sont utilisées en glottochronologie et en lexicostatistique, qui sont deux domaines ouverts par Morris Swadesh.

2.1. La linguistique historique

La glottochronologie¹, et la lexicostatistique² sont des techniques utilisant les listes de Swadesh. Cependant, bien que ces listes soient toujours utilisées, ces deux méthodes ont fait place à une application récursive de reconstruction de langue, plus adaptée et tenant compte du contexte sémantique, phonétique et syntaxique des langues.

Un phonème est un élément sonore du langage articulé considéré d'un point de vue physiologique (disposition des organes vocaux) et d'un point de vue acoustique (perception auditive). Saussure le définit ainsi : « le phonème est la somme des impressions acoustiques et des mouvements articulatoires, de l'unité entendue et de l'unité parlée, l'une conditionnant l'autre : ainsi c'est déjà une unité complexe, qui a un pied dans chaque chaîne » (SAUSSURE 2005) La phonologie l'étude des phonèmes. Ces phonèmes ont donc des caractéristiques différentes, se différenciant entre eux de par leur prononciation. Ainsi, nous allons évoquer quelques notions de phonétique. La phonétique s'appuie principalement sur des caractères physiques qui permettent la prononciation. De nombreux sons peuvent être produits et sont répertoriés dans des tableaux phonétiques (SAUSSURE 2005) (voir image).

Ainsi, on peut voir que la prononciation des phonèmes et des sons proviennent de parties très variées du corps humain.

Les phonèmes sont susceptibles d'évoluer dans le temps suivant des « lois phonétiques ». De plus, les phonèmes, dans une langue, peuvent apparaître ou disparaître, comme par exemple le /h/ aspiré au 17^{ème} siècle, cette disparition s'étalant jusqu'au 19^{ème} siècle. L'évolution des phonèmes est due principalement à la loi appelée « *paresse articulatoire* » : ce qui est trop difficile à articuler est automatiquement simplifié. C'est ainsi que les mots ont été raccourcis, par disparition des syllabes les plus faibles. Des consonnes se sont affaiblies : placées entre 2 voyelles (intervocales), elles ont été influencées, se sont sonorisées, et ont pu disparaître. Ce phénomène aboutit à la longue à de profondes transformations de la morphologie, comme la chute des déclinaisons, et la modification des conjugaisons. (par exemple, "pater" en latin est devenu "père" en français, ou encore par exemple, le « s » final de "plus" était autrefois prononcé, mais est devenu muet au fil du temps.

Cette loi de simplification est compensée par la loi d'« *intelligibilité* », la nécessité de clarté dans l'expression : il faut que les mots et les phrases restent compréhensibles ; on a donc conservé certains phonèmes pour éviter que la réduction n'amène des homophones, ou que la phrase devienne obscure. (Par exemple, le son [e] a évolué en "è" ou "ê", et le son [o] a évolué en "au" ou "eau". De plus, les voyelles suivant une consonne nasale ont tendance à se nasaliser, comme dans le cas de "enfant" où le "a" est nasalisé.)

1. La glottochronologie est la méthode de datation des langues proposée par Swadesh, fut comparée à la détermination de l'âge des fossiles à partir de la désintégration radioactive du carbone 14 (elle n'est cependant plus utilisée car sujette à beaucoup d'inexactitudes).

2. La lexicostatistique est une méthode utilisée en linguistique comparative et historique pour mesurer la proximité entre différentes langues. Elle se base sur l'analyse statistique des mots partagés entre ces langues, notamment les cognats, c'est-à-dire les mots ayant une origine commune. Cette approche permet d'évaluer le degré de parenté entre deux langues et de reconstituer leur histoire évolutive. En comparant la fréquence des cognats, on peut ainsi déterminer si les langues étudiées sont issues d'une même langue ancestrale. Toutefois, la lexicostatistique présente des limites, notamment en raison de possibles emprunts ou convergences culturelles qui peuvent fausser les résultats.

Pour terminer avec la phonétique, voici quelques principes qui régissent les modifications phonétiques à travers le temps : La palatalisation, la diphtongaison, la disparition des voyelles, la liaison ou encore la nasalisation (cf annexe).

2.1.3 Les atouts de l'Intelligence Artificielle dans ce domaine

La linguistique historique fait face à de nombreux problèmes récurrents (traiter une grande quantité de textes pour l'homme, remarquer des motifs dans ces documents historiques). Alors que ce travail pourrait être effectué par une machine, grâce à sa capacité à traiter un grand nombre de données, et à chercher des similarités dans ces données. Avant, de voir les tâches où l'Intelligence Artificielle peut intervenir, il est d'abord nécessaire de voir en détail la conception de ces IA.

Résoudre des problèmes de Linguistique Historique avec un ordinateur nécessite de lui faire traiter du contenu textuel devant être abstrait sur des terrains parmi ceux de la **phonétique**, de la **sémantique**, de la **morphologie** ou encore de la **syntaxe**.

Développer un exemple pour illustrer ces 4 niveaux d'abstractions

La réalisation de ces abstractions s'inscrit dans le Traitement Automatique des Langues (TAL), un domaine à cheval entre la Linguistique et l'Informatique. L'Intelligence Artificielle y occupe une place centrale pour sa capacité à effectuer des approximations améliorables avec de l'entraînement.

2.2 L'intelligence artificielle dans le Traitement Automatique des Langues

2.2.1 Introduction à l'apprentissage automatique

Qu'est ce qu'une intelligence artificielle ?

Qu'est ce qu'un réseau de neurones ?

Quel est le principe derrière l'apprentissage automatique ?

Définition des apprentissages supervisés/non supervisés Définition de propagation avant. Définition rétro-propagation du gradient. Exemple de FFNN pour tâche de classification

Un important nombre de problèmes informatiques peut être résolu à travers la détermination d'une fonction mathématique f d'un espace vectoriel \mathbb{K}^n vers un espace vectoriel $\mathbb{K}^{n'}$ (avec \mathbb{K} correspondant à \mathbb{R} ou \mathbb{C}).

Lorsqu'un algorithme conventionnel est développé pour réaliser un tâche, f a déjà implicitement été trouvé. Par exemple, derrière un traitement opéré sur une chaîne de caractères, elle existe bien, avec pour entrée une séquence de n caractères encodés sous forme de bits qui forme un vecteur de l'espace \mathbb{R}^n et pour sortie un élément d'un espace $\mathbb{R}^{n'}$ représentant la chaîne de sortie.

En revanche, de nombreux cas demeurent où il est difficile – voire impossible – de poser une expression mathématique ou un algorithme pour répondre à certains problèmes. On considère alors f comme hypothétique et on cherche à l'approcher à partir d'un **modèle**, qu'on construit à partir des informations qu'on dispose sur f , comme un ensemble de ses points $\{(x_k, y_k = f(x_k)), k \in S\}$, à travers une tâche dite de **régression**.

Les **réseaux de neurones** sont des outils performants pour établir des modèles. Mathématiquement, ce sont des compositions d'applications non-linéaires et linéaires recevant un vecteur d'entrée représentant une donnée et sortant un vecteur de sortie représentant un résultat dans un format cohérent avec le problème.

Définitions, du neurone au réseau

Le neurone artificiel le plus élémentaire effectue la **somme pondérée** des coefficients du vecteur d'entrée, à laquelle il ajoute une valeur de **biais** pour enfin calculer l'image de la somme à travers une fonction non-linéaire dite **d'activation**. La sortie du neurone est donc un réel ou un complexe. Si on la note y_i , qu'on note x le vecteur d'entrée dans \mathbb{K}^n , w_i le vecteur de **poids** associé au neurone, b_i son biais et σ sa fonction d'activation, on a :

$$y_i = \sigma(b_i + \sum_{j=0}^n w_{ij}x_j) = \sigma(b_i + \langle w_i, x \rangle) \quad (2.1)$$

(JURAFSKY et J. H. MARTIN 2023, chap. 7, section 1)

Une **couche de neurones** est la mise en commun d'un nombre arbitraire N de neurones devant prédire des sorties y_i différentes. Leurs vecteurs de poids w_i différeront donc. En revanche, leur fonction d'activation est identique. La sortie d'une couche est donc un vecteur y pouvant s'écrire comme dans l'équation 2.2³.

$$\begin{aligned} y &= \begin{pmatrix} \sigma(b_1 + \langle w_1, x \rangle) \\ \sigma(b_2 + \langle w_2, x \rangle) \\ \vdots \\ \sigma(b_i + \langle w_i, x \rangle) \\ \vdots \\ \sigma(b_N + \langle w_N, x \rangle) \end{pmatrix} = \sigma \begin{pmatrix} b_1 + \sum_{j=0}^n w_{1j}x_j \\ b_2 + \sum_{j=0}^n w_{2j}x_j \\ \vdots \\ b_i + \sum_{j=0}^n w_{ij}x_j \\ \vdots \\ b_N + \sum_{j=0}^n w_{Nj}x_j \end{pmatrix} \\ &= \sigma \left(\begin{pmatrix} b_1 \\ b_2 \\ \vdots \\ b_i \\ \vdots \\ b_N \end{pmatrix} + \begin{pmatrix} w_{11} & w_{12} & \dots & w_{1j} & \dots & w_{1n} \\ w_{21} & w_{22} & \dots & w_{2j} & \dots & w_{2n} \\ \vdots & \vdots & \ddots & \vdots & \ddots & \vdots \\ w_{i1} & w_{i2} & \dots & w_{ij} & \dots & w_{in} \\ \vdots & \vdots & \ddots & \vdots & \ddots & \vdots \\ w_{N1} & w_{N2} & \dots & w_{Nj} & \dots & w_{Nn} \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \\ \vdots \\ x_j \\ \vdots \\ x_n \end{pmatrix} \right) = \sigma(b + Wx) \end{aligned} \quad (2.2)$$

Un réseau neuronal est ainsi formé à partir de la mobilisation d'une ou plusieurs couches. L'intuition derrière l'utilisation de couches intermédiaires, qu'on nomme des **couches cachées**, est que la machine puisse être capable d'apprendre à construire des **représentations adéquates** des données pour effectuer la prédiction finalement voulue avec pertinence. On parle alors d'**apprentissage**

3. On y confond la fonction d'activation avec la fonction vectorielle σ s'appliquant indépendamment à chaque coefficient.

profond et cette technique offre des réponses face aux difficultés d'abstraction soulevées par les problèmes de TAL.

L'agencement des couches et la manière de calculer la sortie finale à partir de chacune d'elles, qu'on peut rassembler sous le terme de « mode de **propagation** », est un **paramètre architecturale** à part entière qu'il faut judicieusement définir en fonction de la tâche à réaliser. Pour traiter de l'utilisation de l'IA dans le TAL, au moins deux principaux types de réseaux de neurones seront introduits au cours de ce chapitre, différant par la nature cyclique ou non de l'enchaînement de leurs couches internes.(JURAFSKY et J. H. MARTIN 2023, chap. 7, introduction + section 3) [*ajouter illustration*]

Processus d'apprentissage

L'entraînement d'un réseau de neurones s'effectue à travers des **ajustements des poids et des biais dans chaque couche**, dans le cadre d'une **minimisation d'une fonction de perte**⁴. Cette fonction doit être choisie judicieusement selon le problème puisqu'elle exprime l'écart entre les sorties prédites et les sorties ciblées au passage de données d'entrée d'entraînement. Sa minimisation est réalisée par un algorithme de **descente du gradient**, avec le gradient de la fonction de perte selon tous les poids du réseau qui est calculé grâce à un procédé de **rétropropagation de l'erreur**, une adaptation pour les réseaux de neurones de celui de la discrimination rétropropagative pour des graphes d'exécution quelconques. Plusieurs implémentations de cet algorithme, qu'on nomme des **optimiseurs**⁵, existent et la nature de l'optimiseur dans un modèle fait partie de ses paramètres d'entraînement.

Des hyperparamètres pour l'entraînement sont également amenés à être définis en pratique, tels que le **taux d'apprentissage**, fixant la valeur maximale de variation qu'un poids ou biais peut subir au cours d'une rétropropagation, le nombre d'**époques** (*epochs*), i.e. de balayages de l'ensemble des données du set d'entraînement pour l'exécution des descentes, et enfin la taille des **lots** (*batches*), i.e. des groupes de données d'entraînement à envoyer au modèle en une fois⁶.(JURAFSKY et J. H. MARTIN 2023, chap. 7, p. 17-23).(FOURRIER 2022, p. 21)

ajouter la nécessité d'initialiser aléatoirement les poids

Concevoir correctement

La phase d'entraînement du réseau s'arrête lorsque le gradient cesse de décroître. Les hyperparamètres ainsi que certains paramètres architecturaux (nombre de couches, leur dimension) ont le mérite d'être réglés dans des configurations différentes afin de s'assurer d'une convergence optimale du gradient (qui des fois n'arrive pas ; cf. overfitting + vanishing gradient -> évoquer plus tard pour introduire les LSTM)

4. aussi appelée fonction de coût, ou d'erreur

5. Adam(KINGMA et BA 2017) en est un assez connu et est celui qui était prévu d'être utilisé pour le codage de l'expérience.

6. Cette quantité est pensée pour prévenir les problèmes de saturation de la mémoire des ordinateurs, qui sont favorisés par les ordres de grandeur souvent importante des tailles des jeux de données d'entraînement.

2.2. L'intelligence artificielle dans le Traitement Automatique des Langues

La phase d'évaluation du modèle se fait à partir de comparaisons des résultats sortis avec des résultats ciblés pour un set de données dit d'évaluation. Plus particulièrement en TAL, on cherche à trouver des exemples afin de déterminer les cas qu'il a su apprendre à correctement gérer ou non.

On peut également établir des métriques pour quantifier le taux de pertinence du modèle. Par exemple la distance d'édition entre les mots sortis et les mots ciblés, dans le cas de la prédiction de mots.

Quoiqu'il en soit, le choix de tous les paramètres se fait expérimentalement, à partir d'intuitions basées sur des observations lors de travaux antérieurs sur de la conception de réseaux. Pas de démonstrations mathématiques (que statistiques).

Transition vers la section suivante

Présentation du FFNN pour une tâche de classification

introduire le réseau FFNN

fonction d'activation softmax à la fin

entropie croisée pour la fonction de perte

2.2.2 Traitement des données

Avant de donner à un réseau de neurones des données au format quelconque, que ce soit pour son entraînement ou pour réaliser des inférences dessus, il est nécessaire de les pré-traiter. Le but est de les rendre correctes et compréhensibles pour l'intelligence artificielle. Leur transformation se fait selon le type de tâche souhaitée. Néanmoins, dans sa généralité, les étapes de préparation des données en TAL restent les mêmes.

Normalisation

Tout d'abord, il faut normaliser (nettoyer) la base de données qui peut être, par exemple, un corpus de textes, une liste de mots, provenant de la toile, ou d'un système de transcription audio-visuelle. Dans ces données se trouvent des chaînes de caractères sous un certains format, où de la ponctuation peut apparaître, de même que des lettres en capitale, des chiffres, des caractères spéciaux (comme le dièse que l'on retrouve souvent dans les *tweets*). . . Mais une partie de ces éléments peut ne pas avoir d'intérêt à être traitée par les algorithmes et même apporter du bruit en fournissant des données incorrectes pour entraîner l'intelligence artificielle. Une première étape est donc de s'en débarrasser ou bien d'apporter des modifications à l'aide d'algorithmes de traitement de texte classique⁷ (JURAFSKY et J. H. MARTIN 2023, chap. 2). [Exemple]

7. les Expressions Régulières sont par exemple de puissants outils pour modifier le contenu textuel

Tokenisation

Après avoir nettoyé la base de données, il faut définir une segmentation des textes en éléments d'entrée pertinents pour un traitement par l'IA : les *tokens*. La tokenisation correspond à la segmentation de chaînes de caractères (comme notre texte) en tokens (mots, sous-mots, caractères, ponctuations). L'ensemble des tokens uniques d'un texte se nomme : vocabulaire.

Prenons un exemple « J'aime les bananes », une approche naïve est de tokeniser notre texte suivant les espaces⁸ ce qui nous donne les tokens [« J'aime », « les », « bananes. »] avec un vocabulaire de taille 3 (dans cette phrase tout les tokens sont uniques). Cependant, cette approche pose des problèmes, en commençant par le token « bananes. » qui a la même signification avec ou sans point, mais qui sera considéré comme différent pour une IA. Nous pourrions ajouter la séparation suivant la ponctuation, mais alors nous obtiendrons pour « J'aime » les tokens [« J », « ' », « aime »] qui est une forme tout aussi problématique. Et il existe encore de nombreux cas (les abréviations, les points de suspension, etc.) où ce type de tokenisation pose problème. Une approche alternative est de tokeniser suivant des règles définies, par exemple, de prendre en compte les contractions comme « J'aime » et de le transformer en deux tokens [« Je », « aime »], qui est une méthode beaucoup plus efficace que la première approche, mais montrera des limites face à des situations (ou mots) rares, ou alors il faudrait spécifier de nouvelles règles pour gérer ces cas. Ainsi, la solution proposée est une approche statistique, consistant à décomposer de plus en plus un mot en sous-mots⁹ au fil que sa fréquence diminue. [Exemple].

Les quatres algorithmes de tokenisation en sous-mots les plus utilisées sont le *Byte-Pair Encoding* (Sennrich et al., 2016), l'*unigram language modeling* (Kudo, 2018), le *WordPiece* (Schuster et Nakajima, 2012), et le *SentencePiece*¹⁰ (Kudo et Richardson, 2018). (JURAFSKY et J. H. MARTIN 2023, chap. 2)

Encodage

Pour la tâche de classification, vous avez vu que les mots d'entrées, [exemple], étaient convertis en une liste de nombre, autrement dit un vecteur, sur lequel il a été effectué des calculs afin d'obtenir un résultat (un nouveau vecteur), [exemple]. Une machine, un réseau de neurones, ne comprend que des nombres et ne sait procéder qu'à des calculs. Il existe différentes façons de convertir un token en un vecteur numérique, mais on retiendra deux méthodes l'encodage 1 parmi n et le plongement lexical (respectivement et plus communément appelés en anglais le *one-hot encoding* et le *word embedding*).

L'encodage 1 parmi n consiste à créer un vecteur binaire de la taille du vocabulaire $|V|$, c'est-à-dire, que chaque dimension correspond à un mot dans le vocabulaire. Dans ce vecteur binaire, la valeur est 1 pour la dimension correspondant au mot dans le vocabulaire, et 0 pour toutes les autres

8. Vous remarquerez déjà que ce processus ne s'applique pas aux langues, comme le Japonais ou le Chinois, manquant d'espace entre les caractères.

9. Remarquez que le terme *mot* a un sens différent de celui qui le précède.

10. Cet algorithme est une implémentation des deux premiers.

2.2. L'intelligence artificielle dans le Traitement Automatique des Langues

dimensions. Ainsi, en supposant que la dimension du mot « bananes » se trouve à la troisième dimension (c'est le troisième mot de notre vocabulaire V), sa représentation correspondra à un 1 à la troisième dimension du vecteur et à des 0 sur les autres dimensions, soit le vecteur :

$$\begin{bmatrix} 0 & 0 & 1 & 0 & \dots & 0 \end{bmatrix}$$
$$1 \quad 2 \quad 3 \quad 4 \quad \dots \quad |V|$$

(JURAFSKY et J. H. MARTIN 2023, Chap 7)

Comme vous pouvez le voir l'avantage de cet encodage est sa simplicité de mise en oeuvre. Mais le problème survient quand le vocabulaire devient très grand, les vecteurs générés, par définition, deviennent à leurs tours très grands et très dispersés (beaucoup de 0 et peu de 1), ce qui entraîne une augmentation de la complexité du modèle (le nombre de dimension pour décrire les données) et des temps de calcul. De plus, cet encodage ne prend pas en compte les relations sémantiques entre les mots, la similarité entre deux mots ne peut être mesurée, car ils sont encodés de façon indépendante les uns des autres, ce qui peut être particulièrement problématique pour les nombreuses tâches de TAL tel que la compréhension ou traduction d'une langue.

Le plongement lexical, en revanche, permet de représenter les mots en encapsulant leur *sens sémantique* par des vecteurs denses de plus faibles dimensions, c'est à dire des vecteurs de nombres réels de petites tailles. Pour obtenir le plongement des tokens, c'est-à-dire, transformer des tokens en vecteurs, une matrice de plongement lexical est utilisée, obtenus par l'entraînement d'un modèle¹¹. Cette matrice contient, à chaque ligne, le vecteur de plongement lexical d'un token du vocabulaire, et à chaque colonne correspond une dimension du vecteur de plongement. Par ailleurs, les dimensions de ces vecteurs n'ont pas une représentation claire (JURAFSKY et J. H. MARTIN 2023, chap. 6). Cette matrice représente un espace vectoriel contenant les plongements des tokens d'un vocabulaire, ainsi, les propriétés vectoriels peuvent s'appliquer pour nos tokens vectorisés. Par exemple, étudier la similarité entre deux mots revient à calculer la distance entre les deux vecteurs correspondants, ou encore comme la figure X le montre, les vecteurs peuvent s'additionner/se soustraire permettant d'obtenir un nouveau vecteur qui garde une cohérence sémantique face à ces opérations. [Figure : Exemple de vecteurs sémantiques montrant bien qu'ils portent un sens et permettent des relations sémantiques entre eux ; vecteur "king" – "man" + "women" – > "queen"].

2.2.3 Architectures neuronales utiles au TAL

Quels sont les différents outils ?

En TAL, le besoin de pouvoir faire comprendre à l'IA des informations **contextuelles** s'est fait ressentir. Par exemple, pour étudier la langue sur le plan syntaxique, une tâche usuelle est

11. Ces modèles apprennent généralement, de façon non supervisée à partir d'un grand corpus de texte, les relations sémantiques et syntaxiques qui peuvent exister entre les mots. Nous pouvons citer, comme exemple de modèle, Word2Vec, GloVe, Bert, qui sont souvent utilisés pour créer des matrices de plongement lexical. Pour approfondir l'obtention de ces matrices, nous vous invitons à regarder (JURAFSKY et J. H. MARTIN 2023, chap. 6, 7, 11)

d'attribuer à chaque mot d'une phrase sa nature grammaticale (*part-of-speech tagging*). La phrase est alors une **séquence** de *tokens* d'entrée qui sont ici des mots. On représente chacun d'eux par un plongement ou un vecteur one-hot. Une bonne intuition est celle que des représentations calculées en profondeur dans un réseau de neurones pour certains éléments de la séquence seront utiles pour le calcul de prédictions sur d'autres éléments de cette même séquence. De cette manière, dans la phrase « La fin de ce film n'était pas très convaincante. » et dans la phrase « Ce paragraphe n'est pas bien fin. », ce ne peut être qu'à partir de traitements sur l'ensemble de la séquence de mots qu'un modèle d'IA pourrait correctement sortir que le mot « fin » est tantôt un nom, tantôt un adjectif.

Dans cette section, des types d'architectures vont être présentés pour leur capacité à construire de manière puissante des contextes dans des séquences d'information.

Réseaux de neurones récurrents

Grâce à leur architecture cyclique, les Réseaux de Neurones Récurrents (*Recurrent Neural Networks*(RNN)) permettent de prendre en compte un contexte. Étant donné une séquence de n entrées $(x_i)_{1 \leq i \leq n}$, le RNN le plus élémentaire est un enchaînement, comme dans un FFNN, d'une couche cachée avec une autre couche. La sortie est alors inférée avec l'expression :

$$y_i = \sigma(Vh_i) \quad (2.3)$$

¹² La valeur ajoutée du RNN réside dans le calcul de cette couche cachée, qui en plus d'être une fonction de l'entrée x_i de la séquence est également une fonction de la couche cachée qui a été calculée en ayant passé en revue les éléments précédents de la séquence. Une somme pondérée des deux vecteurs est alors effectuée dans la définition de h_i , ce pourquoi deux matrices de poids interviennent :

$$h_i = \sigma'(Hh_{i-1} + Wx_i) \quad (2.4)$$

La propagation du flux d'informations amenant à la sortie d'un modèle RNN pour un certain élément d'une séquence d'entrée peut être illustrée avec le figuré ci-dessous :

[insérer l'illustration](JURAFSKY et J. H. MARTIN 2023, chap. 9, p. 1-4)

De cette façon, on remarque aisément qu'on peut construire des empilements de couches RNN, de la même manière qu'on approfondit l'apprentissage en empilant des couches FFNN. La structure serait semblable à celle présentée ci-dessous :

[figuré montrant comment l'information + le contexte se propage à travers des empilements de couches RNN]

Dans ces schémas, la séquence d'entrées n'a été parcourue que de gauche à droite, mais il existe des problèmes, comme celui mentionné en introduction de cette section, où le contexte à gauche comme à droite d'un élément de la séquence doit être pris en compte. Une configuration architecturale des RNNs peut permettre de construire des contextes de manière *bidirectionnelle*. Dans celle-ci, la couche cachée pour l'entrée x_i est produite à partir de la concaténation des couches cachées ayant balayée respectivement les entrées $(x_1, x_2, \dots, x_{i-1}, x_i)$ et dans l'autre sens les entrées $(x_n, x_{n-1}, \dots, x_{i+1}, x_i)$.

12. Dorénavant, les vecteurs des biais seront gardés implicites dans les expressions afin de les simplifier.

2.2. L'intelligence artificielle dans le Traitement Automatique des Langues

[Illustrer avec un schéma](JURAFSKY et J. H. MARTIN 2023, chap. 9, p. 11-13)

Pour un RNN simple, 3 matrices de poids doivent donc être entraînées (en plus des biais dans chaque couche). En étalant le graphe des connexions inter-couches pour chaque traitement le long d'une séquence de données d'une certaine taille, comme illustré dans le figuré ??, il est possible d'effectuer une rétropropagation similaire à celle avec les FFNNs pour calculer les dérivées partielles de la fonction de perte selon chaque poids de ces 3 matrices.(JURAFSKY et J. H. MARTIN 2023, chap. 9, p. 4-5)

En revanche, il a été observé que la descente de gradient ne se déroule pas correctement pour des séquences de taille trop importante, ce qui empêche les simples RNNs d'exploiter efficacement une information contextuelle se situant au-delà d'un certain voisinage autour du *token* à traiter.(FOURRIER 2022, p. 25-26)

Architecture *Long Short-Term Memory*

Les *Long Short-Term Memories* sont des modèles neuronaux dont l'architecture est une variante à celle des RNNs, conçue expréssément pour repousser les limitations de ces derniers. Pour cela, il faut entraîner le réseau de neurones à focaliser son **attention** sur les bons éléments de contexte.

Une unité LSTM est de ce fait plus complexe qu'une unité RNN, mais elle bénéficie de la même modularité. Ainsi, on peut empiler des LSTMs et construire des LSTMs bidirectionnels de la même manière que décrite plus tôt avec les RNNs.

La complexification architecturale peut dans un premier temps se remarquer d'un point de vue externe en notant que, là où une unité RNN n'est composée que d'une couche cachée qui est une fonction de l'entrée et de la couches cachée périphérique, l'unité LSTM est composée en plus d'une **couche de contexte** qu'elle renvoie et qui est utilisée pour le calcul des couches cachées et de contexte des autres entrées dans la séquence.

D'un point de vue interne, ces deux couches interagissent à travers des **portes** rejetant et promouvant de l'information.

[Expliquer comment les portes permettent de sélectionner l'information contextuelle + transition]

Transformeurs

Précédemment, avec les RNN et les LTSM, nous avons introduit le mécanisme d'attention, permettant au réseau de se focaliser sur la manière dont les mots (éloignés) sont reliées les uns aux autres. Seulement, comme nous l'avons vu aussi, ces réseaux se basent sur des connexions récurrentes, rendant le calcul coûteux et la parallélisation difficile. Ainsi, pour pallier ce problème et gagner en performance, un nouveau modèle de réseau de neurones apparait sous le nom de *Transformers* (Transformeurs en français) dans le papier « Attention Is All You Need » de Vaswani et al. (2017)(VASWANI et al. 2017). Ce modèle de type encodeur-décodeur se base sur l'atten-

tion multi-têtes, l'innovation majeure des *Transformers*¹³ ou plutôt ce qui s'y trouve à l'intérieur l'auto-attention (*self-attention* en anglais).

L'attention multi-têtes permet d'étudier tous les vecteurs d'entrées, comme des mots, en même temps (de façon parallèle), et dont chaque tête qui la compose se focalise sur un aspect des *interactions* entre les différents éléments de la séquence, [exemple].

Chaque tête contient un module d'auto-attention qui est utilisé pour permettre à chaque tokens x_i de pouvoir *interagir* avec tous les autres tokens de la séquence $X = (x_1, x_2, \dots, x_n)$. Pour cela est extrait, pour chaque x_i , un trio de vecteurs : un vecteur requête (*query*) q_i , un vecteur clé (*key*) k_i , un vecteur valeur (*value*) v_i . Le vecteur requête correspondant au vecteur sur lequel on porte notre attention et qui sera comparé à tous les autres vecteurs, nommés les vecteurs clés. Puis, le vecteur valeur qui sera multiplié par le poids d'attention calculé avec les autres vecteurs (requêtes et clés). [Figure : Exemple de la formation des différents vecteurs q_i, k_i, v_i suivant une phrase X]. Pour créer ces vecteurs, les vecteurs x_i sont multipliés avec les matrices de poids (W^Q, W^K, W^V) qui sont obtenus à l'entraînement du modèle :

$$q_i = W^Q x_i \quad ; \quad k_i = W^K x_i \quad ; \quad v_i = W^V x_i \quad (2.5)$$

On pose les matrices Q, K, V respectivement l'ensemble des vecteurs q_i, k_i, v_i .

Ensuite, le calcul d'auto-attention pour une tête s'effectue par la multiplication du score d'attention (QK^T), normalisé par la racine carrée de la dimension d_k de la matrice Q et K , et par la fonction *softmax*, avec la matrice des valeurs V :

$$Attention(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V \quad (2.6)$$

Enfin, la matrice d'auto-attention de toutes les têtes sont concaténées en une unique matrice qui est multipliée par une matrice de poids W^O (également obtenus à l'entraînement) pour former la matrice résultante de l'attention multi-têtes : [Figure : résumant toute les étapes.]

$$MultiHeadAttention(X) = \text{Concat}(head_1, head_2, \dots)W^O \quad (2.7)$$

où $head_i = Attention(Q_i, K_i, V_i)$
avec $Q_i = XW_i^Q$; $K_i = XW_i^K$; $V_i = XW_i^V$
et i allant de 1 au nombre de têtes définis.

[Prenons un exemple : ...]

13. Par simplification, nos efforts se concentreront sur l'attention multi-têtes, sans évoquer qu'un *Transformers* se décompose en blocs de *transformer*, dont chaque bloc contient une unité d'attention multi-têtes (masqué ou non) et un FFNN, accompagné de connexions résiduelles et des couches de normalisation. Pour plus de détails, nous vous invitons à regarder le papier de Vaswani et al. (2017)(VASWANI et al. 2017).

2.2. L'intelligence artificielle dans le Traitement Automatique des Langues

Cependant, au tout début, nous avons évoqué que le modèle étudié tout les tokens x_i en même temps, entraînant que le modèle ne tient pas compte de l'ordre des tokens, une information pourtant capitale. Par conséquent, pour injecter l'information de la position de nos tokens dans les vecteurs d'entrées, le papier Vaswani et al. (2017)(VASWANI et al. 2017) propose une solution en additionnant, à nos tokens plongés (vectorisés), des vecteurs positions créent à base de fonction sinus et cosinus¹⁴. Ainsi, cette méthode permet à notre modèle de travailler avec tous les tokens x_i , de notre séquence X , en même temps, tout en ayant l'information de leur position (dans la séquence) dans leur vecteur.

Dans certaines situations, notamment dans la tâche de modélisation de langue en TAL, où le but est de prédire le prochain mot d'une phrase, l'entraînement avec ce type de Transformeur est assez inapproprié, car vous connaissez déjà le prochain mot de votre phrase vu que vous étudiez tous les mots en même temps. Le modèle apprendra juste, à son entraînement, de renvoyer en sortie les tokens d'entrées. Pour résoudre ce problème, les chercheurs¹⁵ propose d'appliquer un masque tel que les valeurs de la partie triangulaire supérieure de la matrice QK^T (le score d'attention) sont remplacés par des $-\infty$ (qui seront transformés en 0 par la fonction *softmax*). Cette variante se nomme l'auto-attention masquée. De ce fait, le champ de visibilité de notre modèle sera réduit au mot qu'il est en train de voir et à ceux qu'il a déjà vu, et pourra prédire de façon plus correcte (sans triche) les prochains mots de nos phrases. [Figure : montrant la matrice réduite]

14. Nous invitons le lecteur à regarder le papier de (VASWANI et al. 2017) pour se convaincre de la pertinence de ce choix d'encodage de position. Simplement, reprenez que cela permet au modèle de s'entraîner avec la position relative des tokens, plutôt que la position absolue.

15. Ils ont proposé cette variante car leur modèle de *base* répondait aux problématiques des réseaux récurrents pour la traduction machine.

3 Les contributions de l'IA dans la linguistique historique

Petite introduction avant de passer au papiers.

Ainsi, après avoir énoncé les différents principes de l'intelligence artificielle dans le traitement automatique des langues, nous allons aborder les applications directes de l'intelligence artificielle à la linguistique historique.

3.1 Restauration de documents anciens

La restauration d'inscriptions endommagées nécessite que les épigraphistes s'appuient sur de vastes bases de données pour trouver des parallèles textuels et contextuels. Ces référentiels sont principalement constitués du répertoire mnémotechnique des parallèles d'un chercheur et, plus récemment, de corpus numériques permettant d'effectuer des recherches par « correspondance de chaînes de caractères ». Cependant, des différences dans la requête de recherche peuvent exclure ou obscurcir des résultats pertinents, et il est presque impossible d'estimer la véritable distribution de probabilité des restaurations possibles. L'attribution d'une inscription est tout aussi problématique : si elle a été déplacée ou si des éléments de datation internes utiles manquent, les historiens doivent trouver d'autres critères pour attribuer le lieu et la date de l'écriture (formes de lettres, dialectes, etc). Et cela implique inévitablement, un niveau élevé de généralisation, les intervalles d'attribution chronologique pouvant être très longs.

Ainsi, avec l'utilisation d'Ithaca, nous surmontons les contraintes des méthodes épigraphiques actuelles en utilisant le deep learning, un apprentissage automatique. Les réseaux neuronaux profonds peuvent découvrir et exploiter des modèles statistiques complexes dans de grandes quantités de données. L'augmentation récente de la puissance de calcul a permis à ces modèles de relever des défis de plus en plus sophistiqués dans de nombreux domaines, y compris l'étude des langues anciennes. Ithaca, possède une architecture de réseau neuronal profond (*deep neural network* en anglais) entraînée à effectuer simultanément les tâches de restauration textuelle, d'attribution géographique et d'attribution chronologique. Ithaca, a été formé sur des inscriptions écrites en grec ancien et dans le monde méditerranéen entre le VIIe et le XXe siècle. Ce choix s'explique par deux raisons principales. Premièrement, la variabilité du contenu et du contexte des documents épigraphiques grecs, qui en fait un excellent défi pour le traitement des langues ; et deuxièmement, la disponibilité de corpus numérisés pour le grec ancien, une ressource essentielle pour l'entraînement des modèles d'apprentissage automatique.

L'architecture d'Ithaca a été soigneusement adaptée à chacune des trois tâches épigraphiques,

en traitant de manière pertinente les informations contextuelles à long terme et en produisant des résultats interprétables pour améliorer la synergie entre homme et machine. Pour commencer, les informations contextuelles sont capturées de manière plus complète en représentant les entrées sous forme de mots ; cependant, des parties de mots ont pu être perdues au cours des siècles. Pour relever ce défi, nous traitons le texte d'entrée sous forme de représentations de caractères et de mots conjointement, en représentant les mots endommagés, manquants ou inconnus (unknown) par un symbole spécial « [unk] ».

Ensuite, pour permettre un traitement à grande échelle, Ithaca est basé sur une architecture de type Transformeur, qui utilise le mécanisme d'attention pour évaluer l'influence des différentes parties de l'entrée (telles que les caractères, les mots) sur le processus de prise de décision du modèle. Le mécanisme d'attention est informé de la position de chaque partie du texte d'entrée en concaténant les représentations des caractères et des mots d'entrée avec leurs informations positionnelles séquentielles. Ithaca est constitué de blocs de transformeur empilés : chaque bloc produit une séquence de représentations traitées dont la longueur est égale au nombre de caractères d'entrée, et la sortie de chaque bloc devient l'entrée du suivant. La sortie finale de l'ensemble des blocs est transmise à trois têtes¹ de tâches différentes qui traitent respectivement la restauration, l'attribution géographique et l'attribution chronologique. Chaque tête est constituée d'un réseau neuronal feedforward peu profond, spécifiquement entraîné pour chaque tâche.

Ithaca est conçu pour assister et étendre le travail de l'historien. L'architecture d'Ithaca est axée sur la collaboration, l'aide à la décision et l'interprétabilité. Alors que Ithaca seul atteint une précision de 62% lors de la restauration de textes endommagés, l'utilisation d'Ithaca par des historiens a amélioré leur précision de 25% à 72%, confirmant l'effet synergique de cet outil de recherche. Ithaca peut de plus attribuer des inscriptions à leur emplacement d'origine avec une précision de 71% et peut les dater à moins de 30 ans de leur période de vérité, redonnant ainsi vie à des textes clés de l'Athènes classique et contribuant à des débats d'actualité sur l'histoire ancienne. Cette recherche montre comment des modèles tels qu'Ithaca peuvent libérer le potentiel de coopération entre l'intelligence artificielle et les historiens, en transformant la façon dont nous étudions et écrivons sur l'une des périodes les plus importantes de l'histoire de l'humanité.

Ithaca est ainsi un exemple type de l'utilisation des intelligences artificielles dans le domaine de la linguistique historique. Cependant, l'un des enjeux des chercheurs est d'étendre l'action des intelligences artificielles jusqu'au déchiffrement de langues anciennes, indéchiffrables à ce jour. La plupart de ces langues sont issues de langues mortes, n'ayant pas de locuteurs ni suffisamment de supports physiques permettant son étude approfondie. Le linear B, une écriture mycénienne du deuxième millénaire av. J.-C., a été découvert en Crète en 1900 et compris seulement en 1952, tandis que le linear A, découvert au même moment, n'a toujours pas été déchiffré à l'heure actuelle. On estime qu'à l'heure actuelle, une douzaine de langues sont toujours indéchiffrées. Plusieurs projets en cours de développement, exploitant les données récoltées depuis le début de l'utilisation des intelligences artificielles.

1. Attention ces têtes sont différentes de celles contenues dans les blocs de transformeur, les multi-têtes d'attention.

3.2 Déchiffrement de langues anciennes

Le prochain défi des intelligences artificielles est le déchiffrement de langues anciennes. Pour déchiffrer une langue ancienne, l'objectif des linguistes et archéologues est de trouver des textes appelés des « bilingues », qui permettent à la fois de comparer ces deux langues, et de traduire la langue inconnue, de la même manière que Champollion en 1821. Plus de 200 ans après la découverte de la pierre de Rosette, on peut maintenant affirmer que Champollion a pu déchiffrer l'égyptien autrement que grâce à cette dernière. Elle a en effet servi à amorcer la compréhension du système alphabétique de l'égyptien, mais Champollion a surtout déchiffré l'égyptien grâce au copte, la langue liturgique des chrétiens d'Égypte. L'apport du copte a permis 95 % du déchiffrement, la pierre de Rosette - ou ses équivalents - à peine 5%. Cependant, ces bilingues sont très rares et parfois trompeurs, car rédigés différemment ou erronés dans leur traduction, et les linguistes doivent s'appuyer sur d'autres textes et méthodes.

D'abord, les linguistes essaient déterminer le type de système d'écriture utilisé : une écriture alphabétique ou alpha-syllabique, une écriture qui note chaque syllabe indépendamment, ou alors un système qui comporte des logogrammes c'est-à-dire des signes utilisés pour noter des mots entiers.

Ils travaillent également avec les noms propres contenus dans les textes anciens, permettant de fournir des pistes pour le déchiffrement de l'écriture, comme a pu le faire récemment François Desset pour déchiffrer l'élamite linéaire. C'est grâce à huit vases en argent que l'archéologue français est parvenu à *craquer* le code. Ces huit vases, nommés *vases Gunagis*, vieux de 4 000 ans, présentent des séquences de signes identiques d'une pièce à l'autre. L'archéologue a ainsi pu repérer les noms de deux souverains, Shilhaha et Ebarti II, ainsi que de la divinité Napirisha, qui l'ont petit à petit amené à déchiffrer le reste de l'écriture en élamite linéaire (DESSET et al. 2022).

Plusieurs travaux sur le déchiffrement de langues anciennes avec de l'intelligence artificielle ont été menés, notamment par le MIT en octobre 2020. Les chercheurs du Computer Science and Artificial Intelligence Laboratory (CSAIL) ont réalisé une avancée majeure dans ce domaine (LUO, HARTMANN et al. 2020) : ils ont mis au point un nouveau système capable de déchiffrer automatiquement une langue perdue, sans avoir besoin d'une connaissance *approfondie* de ses relations avec d'autres langues. Les chercheurs ont également montré que leur système peut lui-même déterminer les relations entre les langues et l'ont utilisé pour corroborer des travaux récents suggérant que la langue ibérique n'est pas réellement liée au basque (ASSAEL et al. 2022).

Le système repose sur plusieurs principes issus de la linguistique historique, et serviront de ces principes comme contrainte informatique, par exemple le fait que les langues n'évoluent généralement que de certaines manières prévisibles. En effet, s'il est rare qu'une langue donnée ajoute ou supprime un son entier, certaines substitutions de sons sont susceptibles de se produire plutôt que d'autres. Un mot comportant un « p » dans la langue mère peut se transformer en « b » dans la langue descendante, mais il est moins probable qu'il se transforme en « k » en raison de l'écart important entre les prononciations. L'algorithme apprend à intégrer les sons de la langue dans un espace multidimensionnel où les différences de prononciation se reflètent dans la distance entre

3.2. Déchiffrement de langues anciennes

les vecteurs correspondants. Cette conception leur permet de capturer/modéliser les changements phonétiques. Le modèle qui en résulte peut segmenter les mots d'une langue ancienne et les mettre en correspondance avec leurs équivalents dans une langue apparentée.

L'article propose un modèle de déchiffrement pour extraire les cognats des textes non-segmentés (ou sous-segmentés), sans supposer une proximité entre les langues perdues et les langues connues, comparé à leur papier précédent (LUO, CAO et BARZILAY 2019). Les propriétés linguistiques de chaque langue ont été incorporées dans la conception du modèle, telles que la plausibilité phonétique du changement de son et la préservation des sons. Les résultats de l'étude sur le gothique, l'ougaritique et l'ibérique montrent que leur modèle peut traiter efficacement les textes sous-segmentés, même lorsque les langues source et cible ne sont pas apparentées. En outre, avec leur modèle, ils introduisent une méthode d'identification des langues proches, dont ils trouve correctement les langues apparentées pour le gothique et l'ougaritique. Pour l'ibérique, la méthode n'apporte pas de preuves solides en faveur du basque comme langue apparentée, ce qui correspond à la position privilégiée par les chercheurs actuels (ASSAEL et al. 2022). Les applications potentielles de leur méthode ne se limitent pas au déchiffrement. Les valeurs phonétiques des caractères perdus peuvent être déduites en les mettant en correspondance avec les caractères apparentés connus. Ces valeurs peuvent servir de point de départ à la reconstruction des sons perdus et des recherches supplémentaires sont nécessaires pour établir leur efficacité. En outre, l'efficacité de l'intégration des caractéristiques phonologiques ouvre la voie à de futures améliorations pour la détection des cognats dans la linguistique historique computationnelle. Actuellement, la méthode fonctionne sur une paire de langues. Pour traiter simultanément plusieurs langues, comme c'est souvent le cas dans la tâche de détection de cognats, des travaux supplémentaires sont nécessaires pour modifier ce modèle actuel et sa procédure d'inférence.

4 Étude du cas de l'application de l'IA pour la reconstruction des proto-formes

La méthode comparative décrite en section 2.1.2 permet de comprendre le sens et la prononciation de mots dans une langue perdue à partir de comparaisons avec d'autres langues apparentées dont on dispose de plus de connaissances. Ce problème a de l'importance pour la construction de lexiques et pour la traduction de documents dans des langues déjà déchiffrées. Le cas de l'Étrusque l'illustre bien puisque, bien que déchiffré (des informations sur la phonétique et la syntaxe ont été trouvées), les linguistes ignorent encore à quelles langues le comparer pour comprendre le sens d'un grand nombre de ses mots (*L'écriture et la langue étrusques : histoire d'un déchiffrement et d'une conquête scientifique en cours* 2022).

Des solutions informatiques appliquant cette méthode-là dans des directions différentes ont été développées. Par exemple, l'identification des cognats dans des langues aux origines commune est une tâche pour laquelle des travaux de recherche ont été entrepris et à l'issue desquels de performantes solutions sont sorties (FOURRIER 2022) (MELONI, RAVFOGEL et GOLDBERG 2021, 2 : Related Works). Cependant, notre projet s'est focalisé sur celle de la reconstruction des proto-formes, dont de récentes solutions neuronales sont apparues. Puisqu'une d'entre-elles a fait l'objet de la rédaction de notre article scientifique et de l'élaboration d'une expérience, cet exemple d'application de l'IA va être étudié en détail dans ce chapitre.

4.1 État de l'art

4.1.1 Conceptualisation du problème

Le problème que cette tâche doit résoudre est de prédire la proto-forme la plus probable d'être l'ancêtre d'un ensemble donné de cognats, afin de fournir des ressources hypothétiques pouvant orienter le travail des linguistes. Les indices à suivre pour effectuer la reconstruction sont ici les règles de changement phonétique de la linguistique diachronique.

Puisque ces changements sont supposés être réguliers d'une langue à une de ses descendantes, il est possible de déployer des réseaux de neurones pour les apprendre à partir d'un grand nombre de données, qui sont des paires composées d'un groupe de cognats dans des langues filles et de la proto-forme supposée peut être correctement associée. Toutes les chaînes de caractères sont converties au format phonétique afin que les tokens à manipuler ne soient que des caractères de l'API, représentant des sons.

4.1.2 Dernières solutions neuronales

Approche supervisée

En disposant des données décrites plus tôt, la dernière démarche supervisée conçue ces dernières années s'inspire directement de celles mobilisées usuellement dans les problèmes de **traduction automatique**. Le modèle neuronal est alors doté de l'architecture **encodeur-décodeur**.

L'encodeur reçoit les séquences de plongements associés aux caractères de chaque cognats et encode les informations qui vont être passées dans le décodeur pour générer une proto-forme plausible. Les deux parties sont chacun des réseaux de neurones à part (pour avoir un parallèle avec la traduction automatique plus généralement, voir JURAFSKY et J. H. MARTIN 2023, chap.9, p.17-21). Ici, les architectures choisies sont des *Gated Recurrent Units*, des variantes aux unités LSTM. Pour la traduction entre des langues contemporaines, les Transformeurs sont privilégiés, mais il a été révélé qu'ils nécessitent une quantité de données d'un ordre de grandeur qui n'est pas satisfait par la tâche ci-présente. *TODO : citer une source documentant ça* Nous avons pu l'expérimenter en tentant d'exploiter des modèles de ce type d'architecture avec une technique de *fine-tuning*. Des détails sur nos résultats sont décrits en annexe.

Approche non supervisée

L'ultime modèle étudié dans ce mémoire s'écarte du précédent en proposant de s'affranchir des bonnes reconstructions associées aux cognats pour s'entraîner. Au contraire, il détermine les proto-formes en même temps que d'entraîner les réseaux servant à le faire (HE, TOMLIN et KLEIN 2022).

Pour cela, le système général est probabiliste. Celui-ci admet que la transformation d'une proto-forme vers son cognat dans une certaine langue fille suit un processus dans lequel chaque caractère phonétique de la proto-forme peut subir une suppression ou une substitution suivie d'éventuelles insertions de caractères supplémentaires. Les modèles neuronaux interviennent pour apprendre à estimer les probabilités que ces opérations aient lieu sur le i -ème caractère d'une proto-forme x , en sachant que la forme dans une certaine langue fille actuellement construite avec les précédentes opérations appliquées sur x soit y' . Les réseaux sont alors composés d'une couche avec une architecture LSTM encodant un contexte à partir de x et de y' , suivie d'une couche FFNN de classification renvoyant une distribution de probabilité sur le vocabulaire¹ (HE, TOMLIN et KLEIN 2022, Section 4-5).

L'heuristique principal de l'approche est, qu'étant donné une reconstruction temporaire x_0 pour un ensemble de cognats $\{y_l, l \in L\}$ donné (avec L désignant l'ensemble des langues filles concernées pour la reconstruction), la bonne proto-forme se situe sur un chemin d'édition de taille minimale entre cette reconstruction temporaire et chacun des cognats. Il est donc possible d'établir une liste de candidats $(x_i)_{0 \leq i \leq \Gamma}$ dans laquelle elle se trouve. Le critère de sélection du candidat devrait

1. L'ensemble des caractères phonétiques auquel un caractère spécial est ajouté pour symboliser la suppression ou la fin d'une insertion. Le coefficient j du vecteur de sortie représente alors la probabilité que le j -ième caractère du vocabulaire soit inséré sur y' .

se faire en calculant la probabilité suivante, qu'on développe grâce aux règles de Bayes² :

$$\begin{aligned} p(x|\{y_l, l \in L\}) &= \frac{p(x, \{y_l, l \in L\})}{p(\{y_l, l \in L\})} \propto p(x, \{y_l, l \in L\}) \\ &\propto p(x)p(\{y_l, l \in L\}|x) = p(x) \prod_{l \in L} p(y_l|x) \end{aligned} \quad (4.1)$$

Grâce à un programme dynamique utilisant des inférences dans les modèles neuronaux, le calcul des $p(y_l|x)$ est possible. La probabilité $p(x)$ est calculée à l'aide d'un modèle de langue qui est censé déterminer si une chaîne de caractères phonétiques forme un mot ayant des chances d'exister dans la proto-langue (HE, TOMLIN et KLEIN 2022, Section 5).

Tant que les réseaux de neurones ne sont pas bien entraînés, les échantillons x tirables ne sont pas fiables. Pourtant, c'est bien avec de tels échantillons qu'il va falloir travailler pour créer des données d'entraînement, si l'on souhaite que la non supervision soit conservée.

Les modèles neuronaux gagnent dans ce cas en pertinence à mesure qu'ils reçoivent des entraînements, qui sont alors multiples, et où l'ensemble de couples entrée-sortie pour ajuster les poids neuronaux évolue à chaque fois. Il s'agit d'un algorithme d'espérance-maximisation (DEMPSTER, LAIRD et RUBIN 1977), où un entraînement maximise la vraisemblance d'événements attendus à un certain moment. Ici, lors d'une itération, pour chaque paire de cognats, on tire aléatoirement une forme ancestrale selon une distribution de probabilités sur les candidats définie à partir des probabilités $p(x_i|\{y_l, l \in L\})$. À partir de cet échantillon x , les événements attendus sont que certaines modifications aient eu lieu dessus pour obtenir le cognat y_l . La probabilité des ces modifications est calculable à l'aide à nouveau d'un programme dynamique faisant appel aux modèles neuronaux et on construit de cette façon les données d'entraînement de manière non supervisée. (HE, TOMLIN et KLEIN 2022, Section 6)

Le modèle a pu être testé pour reconstruire le latin à partir des mêmes données que la démarche supervisée, hormis que les formes latines ont intégralement été utilisées pour son évaluation. Il a pu surpasser en performances un ancien modèle entraîné avec une méthode non supervisée probabiliste. En revanche, aucune étude approfondie des règles de changement phonétique apprises n'a encore été entamée (HE, TOMLIN et KLEIN 2022, Section 7).

4.1.3 Limites d'applicabilité

Étant donné que le recueil d'informations phonétiques sur une langue ancienne est facilité par l'identification de cognats phonétisés dans des langues descendantes, on en déduit qu'il existe des cas pratiques de reconstructions où la quantité de ressources sur la proto-langue peut devenir significativement plus mince que celle des ensembles de cognats procurables. Mettre en place un modèle le moins gourmand possible en données sur la proto-langue est donc un objectif présentant de l'intérêt.

Pour aller dans ce sens, la démarche non supervisée dispose d'un net avantage par rapport à l'approche supervisée. Néanmoins, il a été mentionné que la présence d'un modèle de langue de la

2. La dernière égalité est justifiée par la supposition de l'indépendance des apparitions conditionnées des cognats dans les langues filles

4.2. Expérience sur une approche non supervisée

proto-langue était nécessaire, ne la dispensant pas totalement du besoin de mots phonétisés dans la proto-langue à reconstruire.

De ce problème a émergé la question de notre article scientifique : celle des propriétés que le modèle de langue doit respecter pour que le modèle non supervisé puisse prédire des résultats de confiance.

4.2 Expérience sur une approche non supervisée

Pour tenter de répondre à la question posée à la fin de la section précédente, une expérience a été imaginée afin d’avoir un premier aperçu de l’impact que la qualité du modèle de langue peut avoir sur la pertinence des résultats prédits par le modèle de reconstruction proposé par (HE, TOMLIN et KLEIN 2022). Une description synthétique en sera effectuée, mais certains détails seront esquivés, car consultables dans un article rédigé antérieurement (BADOUILLE, CAMOU et HORRUT 2023). Énormément de points sur cette problématique assez complexe ayant été négligés, une réflexion sur les limites de la méthodologie sera aussi abordée. Enfin, une précision sur le déroulé du développement de l’expérience et de son état de conception sera ajoutée dans ce chapitre.

4.2.1 Méthode

Dans un premier temps, les réseaux de neurones d’édition sont initialisés et tous les algorithmes décrits par le papier sont implémentés afin de pouvoir reproduire la reconstruction du latin dans un maximum de conditions expérimentales en commun avec celles des chercheurs qui leur ont fourni les meilleurs résultats.

Dans un second temps, une multitude de modèles de langue aux architectures parmi celles à base de bi-grammes, de tri-grammes (JURAFSKY et J. H. MARTIN 2023, chap. 3) ainsi que la neuronale de type RNN (JURAFSKY et J. H. MARTIN 2023, chap. 9, p. 5-7) sont entraînés sur des jeux de données de taille différente. Les données proviennent d’une autre base de données³ que celle décrite dans le papier des chercheurs.

Enfin, les itérations des espérance-maximisations sont exécutées pour chaque configuration du modèle de langue et les niveaux de pertinence de chaque modèle sont comparés. Comme pour les expériences décrites dans les papiers associés aux approches non supervisée et supervisée, la métrique utilisée est la distance d’édition moyenne (non normalisée et normalisée) entre les reconstructions latines prédites et les vraies reconstructions.

4.2.2 Critiques

Une première limitation présentée par l’expérience est qu’à vouloir uniquement observer un lien de causalité entre la quantité de données fournies à un modèle pour l’entraîner et sa pertinence, l’influence bien plus déterminante de leur hétérogénéité est négligée. Cette dernière propriété est

3. <https://data.statmt.org/cc-100/>

définie ici par la diversité des structures que l’ensemble de mots phonétisés du latin expose. L’expérience a en effet déjà montré que cette qualité avait bien plus d’importance que la quantité de données pour l’entraînement de modèles de langue (L. MARTIN et al. 2020).

Ensuite, rien ne garantit que les résultats pour la reconstruction du latin soient comparables avec ceux pour des reconstructions de d’autres langues. Ce fait est d’autant plus vrai que l’approche non-supervisée de reconstruction en elle-même n’admet pas de performances identiques selon la configuration généalogique des langues concernées par la reconstruction (HE, TOMLIN et KLEIN 2022, Section : Limitations). De plus, il a été mis en évidence que la modélisation de la langue semble admettre des limites de performances intrinsèques à la langue en question (COTTERELL et al. 2018).

Par conséquent, la question de l’applicabilité des dernières démarches neuronales de reconstruction nécessiterait d’obtenir des réponses qui font encore l’objet de débats au sein de la communauté scientifique en TAL. En s’abstenant de ces éléments de complexité, une mise en place de l’expérience pourrait toutefois permettre d’observer si les itérations d’espérances-maximisation sont sensibles aux variations de propriétés des modèles de langue et si leur architecture y joue un rôle. La section suivante décrit les avancées de nos travaux de développement allant dans ce sens.

4.2.3 Compte-rendu de l’élaboration

L’exécution de l’expérience nécessitait d’implémenter la quasi-entière des algorithmes posés dans le papier de HE, TOMLIN et KLEIN 2022. Nous avons alors eu l’ambition de le faire avec Python, en utilisant la librairie PyTorch, qui permet de manipuler les réseaux de neurones avec modularité et performance. Du fait de la nouveauté qu’a représenté l’entraînement en pratique de tels réseaux, le défi était déjà de taille pour nous, mais des difficultés encore plus importantes sont apparues lorsqu’il a fallu programmer d’autres fonctionnalités périphériques, imposées par la non supervision de l’apprentissage.

Par manque de temps, nous n’avons pas pu surmonter tous les obstacles qui se sont dressés face à nous pour terminer de coder l’ensemble des étapes voulues. Néanmoins, une description détaillée de nos avancées va être faite afin d’apporter des réflexions supplémentaires sur l’approche posée par les chercheurs de Berkeley.⁴

Tout d’abord, des questionnements se sont posés à propos des données d’entraînement du modèle de reconstruction que nous avons à disposition. Comme annoncé dans les remerciements, nous avons eu la chance de bénéficier du soutien d’un des auteurs de l’article étudié. Nous l’avons sollicité au départ sur conseil de notre tutrice afin d’obtenir les échantillons de proto-formes des 4 premières itérations d’espérance-maximisations de son expérience, qui était issus d’un ancien modèle probabiliste de reconstruction conçu par BOUCHARD-CÔTÉ et al. 2013. Avec ces échantillons, il nous a alors joint sous formes phonétique et orthographique les cognats français, roumains, portugais, espagnols et italiens ainsi que les bonnes reconstructions latines qui leur était associé. Comme précisé dans son article, leur format différait de celui de MELONI, RAVFOGEL

4. Nos implémentations en Python sont consultables dans ce répertoire

4.2. Expérience sur une approche non supervisée

et GOLDBERG 2021 avec des informations sonores qui ont été retirées. Ce jeu de données a servi de base pour notre encodage des tokens sous forme de vecteur one-hot. Cependant, des anomalies y ont été repérées au niveau de certains cognats français que la librairie *espeak*⁵ a phonétisés par erreur comme des mots anglais.

Plusieurs causes sont derrière ces coquilles. D’abord, la librairie ne sait pas phonétiser tous les mots du dictionnaire français. Ensuite, certains cognats, même sous forme orthographique, n’étaient pas des mots français ! Nous pensons que ces erreurs n’ont toutefois pas impacté grandement l’entraînement de leurs modèles neuronaux d’édition.

En effectuant des comparaisons avec les reconstructions latines et les cognats dans les autres langues, il a été possible de corriger ces défauts. Nos corrections sont affichées dans le tableau ci-dessous.⁶ Il est bon de noter qu’il y a une certaine vigilance à avoir pour déterminer des cognats descendants du latin. En effet, le français par exemple dispose de nombreux mots inspirés de cette langue-là, mais dont la création provient de choix savants et non d’un processus de changement phonétique. Ces mots-ci ne sont alors pas des cognats.

TODO : insérer le tableau avec les corrections

Ensuite, un algorithme de détermination des candidats étant donné un échantillon actuellement sélectionné et ses cognats associés a pu être établi. Une description en est proposée en annexe.⁷ Ce qu’il faut en retenir est que le nombre de candidats à une certaine étape d’échantillonnage est dominé par un terme en 2^d , avec d la plus grande distance d’édition entre la reconstruction actuelle et les cognats. Le modèle a donc tout intérêt à ne pas débiter ses premiers échantillonnages à partir d’échantillons éloignés trop excessivement des cognats, d’où l’utilité des premières itérations d’un autre modèle de reconstruction pour l’initialisation.

Enfin, il a été possible de directement exploiter le code des chercheurs pour les programmes dynamiques, sur lesquels nous avons eu des difficultés de compréhension. Nous ne l’affichons donc pas dans le répertoire de Github, mais ce script a eu une importance centrale et a servi de base pour notre implémentation des inférences dans les modèles neuronaux d’édition.

Dans les fonctions qui restent à développer, une première doit effectuer le tirage aléatoire d’échantillons, qui sera simulé à l’aide d’une chaîne de Markov construite à partir de l’algorithme de Metropolis-Hastings, et dont la loi stationnaire finale sera donné par l’équation ci-dessous, étant donné une variable aléatoire X à laquelle on attribue le numéro de l’échantillon tiré dans la liste des N candidats :

$$p(X = i) = \frac{p(x_i | \{y_l, l \in L\})}{\sum_{j=1}^N p(x_j | \{y_l, l \in L\})} \quad (4.2)$$

L’entraînement des modèles d’éditions à partir des données établies lors d’une espérance-maximisation est aussi encore à programmer. Pour terminer, l’entraînement des modèles de langue du latin n’a toujours pas été géré, de même que la construction des différents jeux de données pour le réaliser.

5. <https://github.com/espeak-ng/espeak-ng>

6. Des erreurs dans les cognats espagnols et italiens ont également été identifiées.

7. Elle aura eu l’intérêt d’apporter des détails qui ont été équivés dans le papier de HE, TOMLIN et KLEIN 2022

5 Conclusion

5.1 Synthèse

Résume tout ce qui a été dit.

5.2 Les différentes limites posées aujourd'hui

une partie des limites aura déjà été traitée dans le chapitre précédent. Cette sous partie se veut résumer ces limites, et aller dans les limites générales (voir acutelles) de l'IA dans la linguistique historique.

5.3 Les perspectives de l'IA dans la linguistique historique

Ouverture, dépassement de certaines limites, évolution des modèles.

Bibliographie

- ASSAEL, Yannis et al. (mars 2022). « Restoring and attributing ancient texts using deep neural networks ». In : *Nature* 603.7900, p. 280-283. ISSN : 0028-0836. DOI : 10.1038/s41586-022-04448-z. URL : <https://www.nature.com/articles/s41586-022-04448-z>.
- ASSOCIATION, International Phonetic (1999). *Handbook of the International Phonetics Association : a guide to the use of the International Phonetic Alphabet*. Press Syndicate of the University of Cambridge. ISBN : 0-521-63751-1, 0-521-65236-7.
- BADOUAILLE, Benjamin, Eliott CAMOU et Thomas HORRUT (avr. 2023). *Mesure expérimentale de la quantité de données phonétiques nécessaire à un modèle de langue ancienne pour une reconstruction non-supervisée de ses proto-formes*. Avec des comment. de Rachel BAWDEN. URL : https://github.com/Convolutio/IA_languesAnciennes/blob/master/Article%5C%20scientifique/Source/article.pdf.
- BOUCHARD-CÔTÉ, Alexandre et al. (2013). « Automated reconstruction of ancient languages using probabilistic models of sound change ». In : *Proceedings of the National Academy of Sciences* 110.11, p. 4224-4229. DOI : 10.1073/pnas.1204678110. eprint : <https://www.pnas.org/doi/pdf/10.1073/pnas.1204678110>. URL : <https://www.pnas.org/doi/abs/10.1073/pnas.1204678110>.
- COTTERELL, Ryan et al. (juin 2018). « Are All Languages Equally Hard to Language-Model? » In : *Proceedings of the 2018 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Volume 2 (Short Papers)*. New Orleans, Louisiana : Association for Computational Linguistics, p. 536-541. DOI : 10.18653/v1/N18-2085. URL : <https://aclanthology.org/N18-2085>.
- DEMPSTER, A. P., N. M. LAIRD et D. B. RUBIN (1977). « Maximum Likelihood from Incomplete Data via the EM Algorithm ». In : *Journal of the Royal Statistical Society. Series B (Methodological)* 39.1, p. 1-38. ISSN : 00359246. URL : <http://www.jstor.org/stable/2984875> (visité le 24/04/2023).
- DESSET, François et al. (2022). « The Decipherment of Linear Elamite Writing ». In : *Zeitschrift für Assyriologie und vorderasiatische Archäologie* 112.1, p. 11-60. DOI : doi:10.1515/za-2022-0003. URL : <https://doi.org/10.1515/za-2022-0003>.
- FOURRIER, Clémentine (sept. 2022). « Neural Approaches to Historical Word Reconstruction ». Theses. Université PSL (Paris Sciences & Lettres). URL : <https://hal.inria.fr/tel-03793299>.
- HE, Andre, Nicholas TOMLIN et Dan KLEIN (2022). *Neural Unsupervised Reconstruction of Protolanguage Word Forms*. arXiv : 2211.08684 [cs.CL].
- JURAFSKY, Dan et James H. MARTIN (2023). *Speech and Language Processing*. 3rd. Stanford University. URL : <https://web.stanford.edu/~jurafsky/slp3/>.
- KINGMA, Diederik P. et Jimmy BA (2017). *Adam: A Method for Stochastic Optimization*. arXiv : 1412.6980 [cs.LG].

- L'écriture et la langue étrusques : histoire d'un déchiffrement et d'une conquête scientifique en cours* (mars 2022). BNF.
- LUO, Jiaming, Yuan CAO et Regina BARZILAY (2019). « Neural Decipherment via Minimum-Cost Flow: from Ugaritic to Linear B ». In : *CoRR* abs/1906.06718. arXiv : 1906 . 06718. URL : <http://arxiv.org/abs/1906.06718>.
- LUO, Jiaming, Frederik HARTMANN et al. (2020). « Deciphering Undersegmented Ancient Scripts Using Phonetic Prior ». In : *CoRR* abs/2010.11054. arXiv : 2010 . 11054. URL : <https://arxiv.org/abs/2010.11054>.
- MARTIN, Louis et al. (2020). « Les modèles de langue contextuels Camembert pour le français : impact de la taille et de l'hétérogénéité des données d'entraînement ». In : *JEP-TALN-RECITAL 2020 - 33ème Journées d'Études sur la Parole, 27ème Conférence sur le Traitement Automatique des Langues Naturelles, 22ème Rencontre des Étudiants Chercheurs en Informatique pour le Traitement Automatique des Langues*. Sous la dir. de Christophe BENZITOUN et al. Nancy / Virtuel, France : ATALA, p. 54-65. URL : <https://hal.science/hal-02784755>.
- MELONI, Carlo, Shauli RAVFOGEL et Yoav GOLDBERG (juin 2021). « Ab Antiquo: Neural Proto-language Reconstruction ». In : *Proceedings of the 2021 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies*. Online : Association for Computational Linguistics, p. 4460-4473. DOI : 10.18653/v1/2021.naacl-main.353. URL : <https://aclanthology.org/2021.naacl-main.353>.
- SAUSSURE, Ferdinand de (2005). *Cours de linguistique générale*. Éd. critique, [Nachdr. der Ausg. 1916]. Payot. ISBN : 9782228889421.
- VASWANI, Ashish et al. (2017). *Attention Is All You Need*. arXiv : 1706.03762 [cs.CL].

biblio

A Fine-tuning

Actuellement, en traduction automatique, le modèle neuronal de type encodeur-décodeur le plus utilisé sont les Transformeurs 2.2.3 qui ont su montré leur performance dans la tâche de traduction automatique (citer références). L'une des raisons de ces résultats est qu'ils peuvent être entraînés sur de grande quantité de données, et se crée une « bonne » représentation de ces données.

Mais, dans le cadre de la reconstruction d'une langue, il faut s'attendre à avoir *peu* (ou pas) de données sur la langue à reconstituer. Dans notre cas, nous souhaitons reconstruire le latin à partir de langue romanes (français, espagnol, italien, portugais), dont nous possédons une base de données contenant environ 5 000 mots phonétisés par langue (latin inclus). Cette base de données est très petite face aux quantités gigantesque (environ des millions de mots) que peuvent traiter les grands modèles de langue.

Ainsi, nous avons décidé d'utiliser des modèles multilingues pré-entraînés dans la tâche de traduction. En effet, pour pallier le « manque » de données d'entraînement, et espérer utiliser les représentations que ce sont construits ces modèles, c'est-à-dire, les relations sémantiques et syntaxiques qu'ils ont pu apprendre, il a été choisis d'utiliser des modèles qui ont déjà été entraînés sur de grandes quantités de données dans les langues romanes. Ici, nous avons choisis les modèles *mBart* (réf modèle + papier) et *mT5* (réf modèle + papier) de chez HuggingFace, qui respectent les critères précédents.

Maintenant, nous devons affiner (*fine-tuning*) les modèles choisis pour notre tâche de reconstruction, c'est-à-dire, que nous allons continuer l'entraînement de ces modèles pré-entraînés avec notre base de données pour qu'ils effectuent non plus la tâche de traduction mais de reconstruction. L'affinement d'un modèle neuronal est un procédé courant quand on souhaite utilisé l'apprentissage (les connaissances) d'un modèle pour l'adapter à la tâche souhaitée (similaire à la tâche initial), surtout quand on ne possède pas assez de données pour entraîner notre modèle en partant de zéro. À préciser que ces modèles ont été pré-entraînés sur des données orthographiques, et non phonétiques, ainsi, pour espérer utiliser les représentations de ces modèles, nous avons fournis notre base de données orthographiques.

La mise en place de l'approche s'est effectué par le téléchargement des modèles, puis la configuration de leur entraînement supervisé et de leur évaluation (par distance d'édition).

Après plusieurs tests d'affinement et d'optimisation d'hyperparamètres de nos modèles, nous n'avons obtenus aucun résultat concluant¹. Plusieurs causes sont possibles, d'abord le manque de données d'entraînement empêchant le modèle d'apprendre la tâche demandée², mais aussi que

1. Une des causes supposées était que les modèles étaient trop grands pour apprendre avec notre base de données, ainsi, des versions plus petites ont été utilisé *tinyBART* (réf) et *mT5 – small* (réf), sans pour autant obtenir de résultats significatifs.

2. Possible que les modèles apprennent avec de plus grandes quantités de données, mais nous sortons du cadre de notre étude consistant à travailler avec des langues où l'on possède peu de données.

nous nous reposons plus sur le principe de régularité de changement phonétique, enfin (architecture transformer). Nous en concluons que l'utilisation de Transformeurs n'est pas approprié pour notre tâche de reconstruction, nous devons nous tourné vers d'autres type de modèle.